От теории к практике: Применение методов математической статистики в реальных задачах

Методы математической статистики в реальном мире

10 апреля 2026 г.

Содержание

1 Оценка каузального эффекта: От снижения дисперсии к Double Machine Learning **2**

1.1 Формализация задачи контролируемого эксперимента 2

1.2 Проблематика: Смещение выборки (Selection Bias) 2

1.3 Решение: Double Machine Learning (DML) 3

1.4 Практический кейс: Валидация метода на полусинтетических данных (CA Housing) 3

2 Оценка неопределенности: От Квантильной регрессии к Conformal Prediction **5**

2.1 Формализация задачи анализа экстремальных значений 5

2.2 Проблематика: Хаотичность границ и физические ограничения 5

2.3 Решение: Split Conformal Prediction 5

2.4 Практический кейс: Динамическая оценка стоимости недвижимости 6

3 Калибровка условных вероятностей при дисбалансе классов **7**

3.1 Формализация задачи оценки редких событий 7

3.2 Проблематика: Операционная пригодность 7

3.3 Решение: Параметрическая калибровка 7

3.4 Практический кейс: Выявление мошеннических банковских транзакций . . . 8

1 Оценка каузального эффекта: От снижения дисперсии к Double Machine Learning

1.1 Формализация задачи контролируемого эксперимента

В индустрии часто используется термин *A/B-тестирование*, который в математической статистике известен как рандомизированное контролируемое испытание (Randomized Controlled Trial). Пусть у нас есть случайная величина Y (например, траты пользователя, отклик) и бинарный индикатор воздействия $T \in \{0, 1\}$ (где $T = 1$ означает применение новой методики).

Наша цель — оценить средний эффект воздействия (Average Treatment Effect, ATE):

$$\theta = \mathbb{E}[Y \mid T = 1] - \mathbb{E}[Y \mid T = 0]$$

В идеальном эксперименте T не зависит от характеристик объекта X. В этом случае несмещенной оценкой θ является разность выборочных средних: $\hat{\theta} = \bar{Y}_1 - \bar{Y}_0$. Однако дисперсия этой оценки $\mathbb{V}(\hat{\theta})$ может быть слишком велика для получения статистически значимых выводов на ограниченной выборке.

Для сужения доверительных интервалов применяется метод **снижения дисперсии (Variance Reduction)**, использующий ковариату — некую величину X, известную до начала эксперимента. Современной модификацией является использование оценки условного математического ожидания, полученной с помощью алгоритмов машинного обучения: $\hat{Y} = \mathbb{E}[Y \mid X]$. Модифицированная случайная величина конструируется как:

$$Y_{adj} = Y - \gamma(\hat{Y} - \mathbb{E}[\hat{Y}])$$

Дисперсия Y_{adj} существенно ниже исходной $\mathbb{V}(Y)$, что позволяет точнее оценить θ.

1.2 Проблематика: Смещение выборки (Selection Bias)

На практике идеальная рандомизация часто нарушается. Возникает проблема обсервационных (наблюдательных) данных, где вероятность получить воздействие T зависит от признаков объекта X. В статистике X называют *смешивающей переменной* (confounder).

Если мы применим наивную оценку $\bar{Y}_1 - \bar{Y}_0$ при наличии зависимости между T и X, оценка $\hat{\theta}$ будет математически смещенной (Рисунок 1). Алгоритмы машинного обучения, обученные напрямую предсказывать Y, «впитают» в себя это системное смещение, показывая ложную корреляцию вместо причинно-следственной связи.

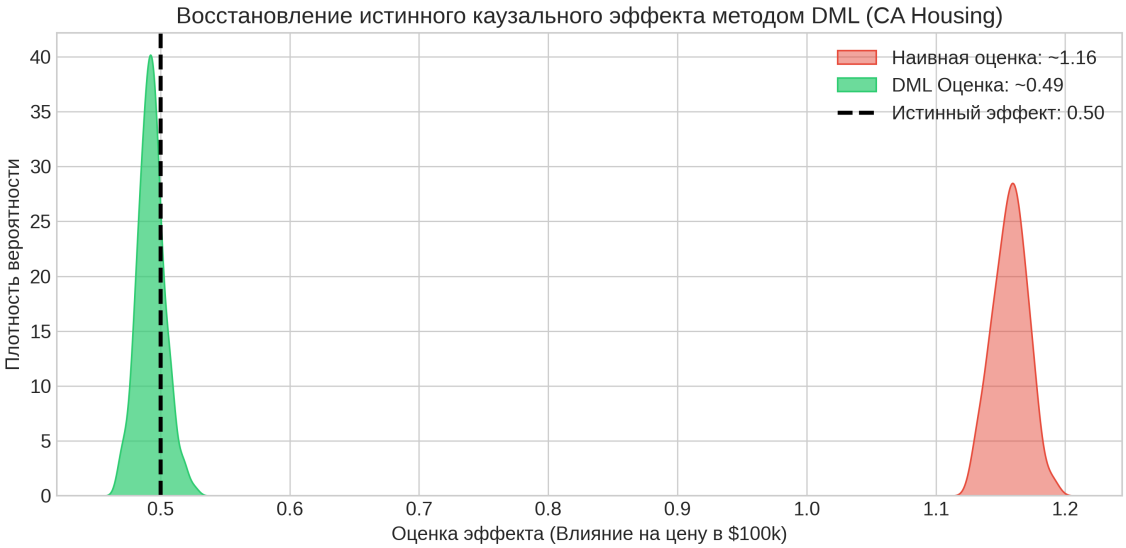

Рис. 1: Оценка каузального эффекта (Полусинтетические данные). Наивная оценка вбирает в себя системное смещение (влияние высокого дохода), показывая ложный завышенный эффект. Метод DML успешно изолирует влияние конфаундеров и находит истинный скрытый эффект (черный пунктир).

1.3 Решение: Double Machine Learning (DML)

Для корректной оценки θ в условиях зависимости T от X применяется метод Double Machine Learning. Предположим частично линейную модель генерации данных:

$$Y = \theta T + g(X) + \epsilon, \quad \mathbb{E}[\epsilon \mid X, T] = 0$$

где $g(X)$ — неизвестная нелинейная функция мешающих факторов. DML использует принцип ортогонализации (теорема Фриша-Во-Ловелла):

1. **Изоляция Y от X:** Обучаем алгоритм машинного обучения оценивать $\hat{q}(X) = \mathbb{E}[Y \mid X]$. Вычисляем остатки (шум, не объясненный X): $\tilde{Y} = Y - \hat{q}(X)$.

2. **Изоляция T от X:** Обучаем модель оценивать условную вероятность воздействия $\hat{p}(X) = \mathbb{P}(T = 1 \mid X)$. Вычисляем остатки: $\tilde{T} = T - \hat{p}(X)$.

3. **Оценка эффекта:** Применяем классический метод наименьших квадратов (МНК) к очищенным остаткам:
$$\hat{\theta} = \left(\sum_{i=1}^{N} \tilde{T}_i^2 \right)^{-1} \sum_{i=1}^{N} \tilde{T}_i \tilde{Y}_i$$

Такой подход нейтрализует влияние мешающих факторов и математически гарантирует асимптотическую нормальность и состоятельность оценки $\hat{\theta}$.

1.4 Практический кейс: Валидация метода на полусинтетических данных (CA Housing)

Постановка задачи: При работе с чисто обсервационными данными истинный эффект воздействия (Ground Truth) неизвестен. Для объективной валидации мы используем **полусинтетический подход**: берем реальные сложные данные для признаков X (доход,

гео-локация), но воздействие T моделируем сами. Мы оцениваем эффект установки системы «Умный дом» ($T = 1$) на стоимость недвижимости (Y).

Генерация данных: Используется база *California Housing*. Вероятность установки T жестко зависит от медианного дохода семьи (MedInc) — чем богаче район, тем чаще ставят системы. Истинный заложенный эффект повышения цены от самой системы (ATE) строго равен 0.500 (в у.е.).

Шаги решения и результаты:

1. **Наивный подход:** Простое сравнение средних дает оценку $\hat{\theta}_{naive} \approx 1.157$. Это классическое смещение выборки: наивная модель приписала системе «Умный дом» эффект богатства самого района, завысив ценность воздействия более чем в два раза.

2. **Применение DML:** Модели изолируют влияние дохода и географии. Очищенная оценка DML составляет $\hat{\theta}_{DML} \approx 0.493$.

3. **Итог:** Метод DML практически идеально выявил истинный скрытый каузальный эффект (0.500), полностью проигнорировав массивный фоновый шум и смещения реальных данных.

2 Оценка неопределенности: От Квантильной регрессии к Conformal Prediction

2.1 Формализация задачи анализа экстремальных значений

В ряде инженерных и бизнес-задач нас интересует не среднее значение случайной величины, а ее границы. Сервис должен гарантировать клиенту, что с вероятностью 95% реальная цена продажи или время ответа не выйдет за указанные рамки:

$$\mathbb{P}(Y \in C(X) \mid X = x) \geq 1 - \alpha$$

Важной особенностью таких систем является **гетероскедастичность** — условная дисперсия $\mathbb{V}(Y \mid X)$ не постоянна, а возрастает с увеличением X. Классический МНК (моделирующий $\mathbb{E}[Y \mid X]$ с постоянной дисперсией) здесь неприменим.

2.2 Проблематика: Хаотичность границ и физические ограничения

Наивные подходы используют глобальную ошибку (RMSE) для построения интервалов. На реальных данных с неравномерной дисперсией симметричные интервалы часто упускают сильные выбросы в сложных сегментах и, что более критично, пробивают физические ограничения (например, выдают отрицательную стоимость).

Кроме того, сложные ансамблевые алгоритмы могут генерировать ступенчатые, хаотичные границы (Рисунок 2). Для отображения пользователям в реальных интерфейсах интервалы должны быть гладкими и физически осмысленными.

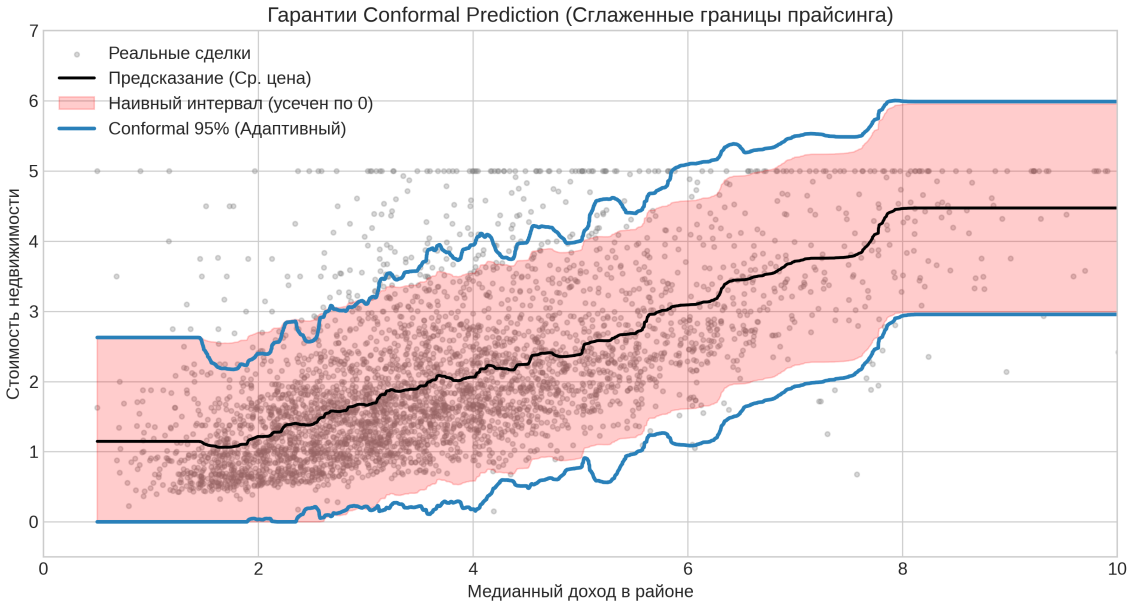

Рис. 2: Прогнозирование стоимости с гладкими границами Conformal Prediction. Наивный интервал проваливается на участках дорогого жилья и жестко усекается нулем внизу. Conformal-интервал адаптивно и гладко расширяется, гарантируя покрытие.

2.3 Решение: Split Conformal Prediction

Конформные предсказания — это статистический аппарат, который позволяет построить предиктивный интервал $C(X)$ поверх *любой* модели $\hat{\mu}(x)$, гарантируя точное покрытие.

Метод опирается на вычисление квантилей нормированных остатков на калибровочной выборке.

Для реальных бизнес-систем вводится условие неотрицательности $max(0, \dots)$, а базовые модели регуляризуются для обеспечения гладкости:

$$C(X_{new}) = [\max(0, \hat{\mu}(X_{new}) - \hat{q} \cdot \hat{\sigma}(X_{new})),\ \hat{\mu}(X_{new}) + \hat{q} \cdot \hat{\sigma}(X_{new})]$$

2.4 Практический кейс: Динамическая оценка стоимости недвижимости

Постановка задачи: Разработка системы оценки стоимости жилья (SLA прайсинга). При росте медианного дохода (X) средняя стоимость домов (Y) растет, но *драматически* увеличивается разброс цен.

Данные: Датасет *California Housing.*

Шаги решения и результаты:

1. **Наивный подход:** Интервал на базе глобального RMSE дает общее покрытие 92.31%. Однако нижняя граница часто становится отрицательной (что физически невозможно), а в сегментах элитного жилья с высокой волатильностью интервал пропускает значительное количество сделок.

2. **Conformal Prediction:** Обучаем вспомогательную модель на предсказание дисперсии. Конструируем динамические интервалы со строгим отсечением по нулю и гладкими границами.

3. **Итог:** Общее покрытие составило 94.57%. Метод адаптивно расширил границы в зоне высоких доходов, надежно выполнив математическую гарантию без нарушения физических ограничений задачи.

3 Калибровка условных вероятностей при дисбалансе классов

3.1 Формализация задачи оценки редких событий

В задачах выявления аномалий (фрод, редкие заболевания) целевая переменная Y бинарна, а классы экстремально несбалансированы: $\mathbb{P}(Y = 1) \ll \mathbb{P}(Y = 0)$.

Современные алгоритмы машинного обучения возвращают некоторое вещественное число $S(x)$ (score), которое **не является** истинной условной вероятностью $\mathbb{P}(Y = 1 \mid X = x)$. Для принятия оптимальных решений (установки порогов блокировки) баллы необходимо **откалибровать** — преобразовать в истинные вероятности.

3.2 Проблематика: Операционная пригодность

Традиционно качество вероятностей оценивается через Brier Score (среднеквадратичную ошибку вероятностей). Изотоническая регрессия (непараметрический метод) идеально минимизирует эту метрику. Однако при экстремальном дисбалансе (доли процента позитивного класса) данных в области высоких вероятностей исчезающе мало.

В результате изотоническая регрессия переобучается на локальный шум и "схлопывает"непрерывные оценки в несколько крупных кластеров-ступеней (Рисунок 3). Модель минимизирует Brier Score, но *полностью теряет способность ранжировать объекты* внутри этих ступеней, что делает ее бесполезной для бизнеса.

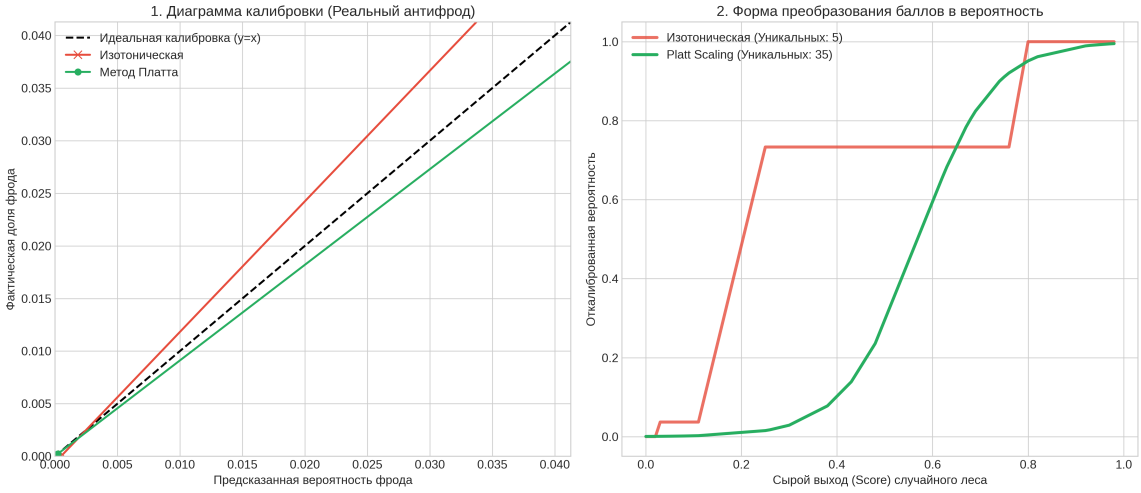

Рис. 3: Диаграмма калибровки на реальных транзакциях. Изотоническая регрессия превращает баллы в "ступеньки"из-за дисбаланса. Параметрический метод Платта (зеленая линия) сохраняет гладкость и высокую разрешающую способность, несмотря на небольшое отставание по Brier Score.

3.3 Решение: Параметрическая калибровка

В условиях дефицита объектов миноритарного класса принято переходить к жестким параметрическим семействам. Метод Платта предполагает логистическую связь:

$$\mathbb{P}(Y = 1 \mid S) = \frac{1}{1 + \exp\left(-(A \cdot S + B)\right)}$$

Коэффициенты A и B находятся методом максимального правдоподобия. Жесткая форма кривой заставляет ее оставаться гладкой, игнорируя локальный шум и сохраняя уникальность оценок каждого объекта.

3.4 Практический кейс: Выявление мошеннических банковских транзакций

Постановка задачи: Система должна выдавать точные вероятности мошенничества для принятия решения о блокировке карты.

Данные: Реальный датасет *Credit Card Fraud Detection* с экстремальным дисбалансом (0.17% фродовых операций).

Шаги решения и результаты:

1. **Сырая модель:** Деревья решений "сжимают"предсказания. Значение Brier Score сырой модели составляет ≈ 0.00089.

2. **Изотоническая регрессия:** Как и ожидается математически, непараметрический подход выдал лучшую метрику Brier Score (≈ 0.00068). **Но ценой операционной пригодности**: алгоритм сжал сотни тысяч транзакций всего в 5 уникальных уровней вероятности. Антифрод-система лишилась возможности выявлять градации риска среди клиентов, попавших в один кластер.

3. **Метод Платта (Platt Scaling):** Логистическая функция показала Brier Score чуть хуже (≈ 0.00082). Однако она сохранила 35 уникальных оценок риска. Эта незначительная потеря в тысячных долях Brier Score с лихвой окупается сохранением строгой монотонности, позволяя бизнесу выстраивать детальный рейтинговый список подозрительных операций.